



Pincay Chilán Daniela

Facultad de Ciencias Matemáticas y Físicas

Universidad de Guayaquil

CDDEIA-ELMA-3-1

Ciencias de Datos e Inteligencia Artificial

Ing. Darwin Rodríguez M.

13 de junio de 2026

Aprendizaje  
Automático

# Comparación de Métricas de Evaluación y Optimización de Modelos de Clasificación

## Introducción

La evaluación de modelos de clasificación es una etapa fundamental dentro del aprendizaje automático, ya que permite determinar qué tan bien un algoritmo realiza sus predicciones. Dependiendo del problema, diferentes métricas pueden resultar más apropiadas para medir el rendimiento del modelo. En este informe se comparan las métricas Precision, Recall, F1-Score y AUC-ROC utilizando como referencia el problema del diagnóstico de cáncer de mama, donde una clasificación incorrecta puede tener consecuencias importantes para los pacientes.

## Precision

La Precision mide la proporción de predicciones positivas que realmente corresponden a casos positivos. Su objetivo es reducir la cantidad de falsos positivos, siendo especialmente útil cuando una falsa alarma representa un costo importante. Matemáticamente se define como:

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

Una alta Precision indica que el modelo rara vez clasifica incorrectamente un caso negativo como positivo.

## Recall

El Recall, también conocido como sensibilidad, mide la capacidad del modelo para detectar correctamente todos los casos positivos existentes.

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

Esta métrica es especialmente importante en aplicaciones médicas, ya que un falso negativo puede impedir que un paciente reciba un tratamiento oportuno.

## F1-Score

El F1-Score corresponde a la media armónica entre Precision y Recall, proporcionando una medida equilibrada entre ambas.

$$\text{F1} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Es una métrica muy útil cuando las clases están desbalanceadas o cuando se desea encontrar un equilibrio entre falsos positivos y falsos negativos.

## AUC-ROC

El Área Bajo la Curva ROC (AUC-ROC) evalúa la capacidad discriminativa del modelo considerando diferentes umbrales de decisión. Un valor cercano a 1 representa un excelente clasificador, mientras que un valor cercano a 0.5 indica un comportamiento similar al azar.

Esta métrica resulta muy útil para comparar distintos modelos independientemente del umbral utilizado para clasificar.

### **Comparación de las métricas**

Cada métrica proporciona información distinta sobre el rendimiento del modelo:

- Precision prioriza minimizar falsos positivos.
- Recall prioriza minimizar falsos negativos.
- F1-Score busca un equilibrio entre ambas.
- AUC-ROC evalúa la capacidad general de discriminación del clasificador.

En problemas médicos como el diagnóstico de cáncer de mama, Recall suele considerarse la métrica más importante debido al alto costo que representa no detectar una enfermedad.

### **Parte 3 – Análisis y Reflexión**

#### **¿Qué método de búsqueda de hiperparámetros fue más eficiente?**

GridSearchCV realiza una búsqueda exhaustiva probando todas las combinaciones posibles de hiperparámetros, obteniendo resultados muy precisos pero con un mayor costo computacional. RandomizedSearchCV explora únicamente una muestra aleatoria del espacio de búsqueda, reduciendo considerablemente el tiempo de ejecución y ofreciendo resultados competitivos cuando existen muchas combinaciones posibles.

#### **¿Cómo afectó el ajuste del umbral a Precision y Recall?**

Al disminuir el umbral de decisión aumentó la cantidad de predicciones positivas, incrementando Recall al detectar más casos reales positivos. Sin embargo, también aumentó el número de falsos positivos, reduciendo Precision. Al aumentar el umbral ocurrió el efecto contrario: mejoró Precision pero disminuyó Recall debido al incremento de falsos negativos.

#### **¿Qué aprendiste sobre la elección de métricas?**

La experiencia demuestra que no existe una única métrica capaz de describir completamente el rendimiento de un modelo. La selección depende del problema específico y del costo asociado a cada tipo de error. En aplicaciones médicas resulta más importante maximizar Recall para evitar pasar por alto pacientes enfermos, mientras que en otros escenarios puede ser más conveniente optimizar Precision. El F1-Score ofrece una evaluación equilibrada y el AUC-ROC permite comparar modelos considerando distintos umbrales de clasificación. Por ello, la evaluación integral de un modelo debe considerar varias métricas de forma conjunta para tomar decisiones fundamentadas.

## Referencias

- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Fawcett, T. (2006). *An Introduction to ROC Analysis*. Pattern Recognition Letters, 27(8), 861–874.
- Géron, A. (2023). *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow* (3rd ed.). O'Reilly Media.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer.
- Murphy, K. P. (2012). *Machine Learning: A Probabilistic Perspective*. MIT Press.
- Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- Powers, D. M. W. (2011). *Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation*. Journal of Machine Learning Technologies, 2(1), 37–63.